

JEAN GOUTTIER

AI Engineer - LLM, RAG et Machine Learning

Montreuil (93), Île-de-France · Mobilité Île-de-France · Ouvert au télétravail hybride ou total

+33 6 51 16 61 89 · gouttierjean@gmail.com

linkedin.com/in/jeangouttier · github.com/JinClaudius · portfolio-gouttier-jean.vercel.app

PROFIL

Ingénieur diplômé Epitech (Bac+5, Architecte de Systèmes d'Information, spécialisation Intelligence Artificielle), avec près de trois ans d'alternance en environnement de production. Je conçois et déploie des systèmes IA opérationnels : intégration de LLM, extraction d'informations structurées, modèles de vision et pipelines de données. Recherche un CDI d'AI Engineer, avec une appétence particulière pour les projets à impact concret.

COMPÉTENCES TECHNIQUES

IA générative & LLM - Intégration d'API LLM, prompting structuré, sorties JSON contraintes, RAG (Retrieval-Augmented Generation), agents IA, pattern ReAct, function calling, orchestration multi-agents, recherche vectorielle par cosinus, streaming SSE, JSON Schema strict, templating de prompts, évaluation de réponses

Machine Learning & Deep Learning - PyTorch, transfer learning, fine-tuning, CNN, EfficientNet, scikit-learn, PCA, Grad-CAM, traitement du déséquilibre de classes, early stopping, métriques F1 / matrice de confusion

NLP - Extraction d'entités, classification de texte, annotation de données, évaluation par métriques

DevOps et industrialisation – Docker, CI/CD, SonarQube, déploiement VPS

Langages - Python, SQL, C#, JavaScript, TypeScript, PowerShell, VBA

Data Engineering - Modélisation et normalisation de schémas, SQL Server, PostgreSQL, Supabase, pipelines ETL/ELT, imports idempotents (MERGE / upsert), qualité de données, pandas

Développement & API - FastAPI, Flask, Node.js / Express, API REST, React, C# / WPF, Git, Postman

Méthodologie - Analyse des besoins, spécifications fonctionnelles et techniques, documentation, tests, fiabilisation de processus

Langues - Français (langue maternelle), Anglais (technique et professionnel)

PROJETS IA

BagTrip - Planification de voyage par agents IA

Chef de projet · n8n · Python · Pilotage d'équipe

Projet de fin d'études Epitech - chef de projet (équipe de 5)

- Pilotage du projet et découpage des tâches de la partie IA, en coordination avec les développeurs back
- Prototypage de l'orchestration sous n8n : workflow fonctionnel enchaînant plusieurs API externes, abandonné au profit d'une implémentation Python pour le contrôle des erreurs et la testabilité
- Suivi de l'architecture retenue : pipeline multi-agents exposé en streaming SSE, RAG par embeddings pour la recommandation, routeur LLM avec fallback multi-modèles

AI-Chat - Chatbot conversationnel avec gestion de contexte

Python · Ollama · LLM local · Projet personnel

- Chat en ligne de commande avec streaming token par token et historique de conversation multi-tours
- Cohérence de l'historique garantie en cas d'échec : le message utilisateur n'est écrit qu'après réponse complète, pour éviter deux messages user consécutifs si le streaming est interrompu
- Gestion de la fenêtre de contexte par estimation en tokens plutôt qu'en nombre de messages, avec déclenchement à 70 % de la fenêtre
- Stratégie de mémoire à deux niveaux : résumé de la conversation et liste de faits durables persistés séparément, avec plafonnement pour éviter la croissance non bornée
- Repli sur troncature de l'historique si la génération du résumé échoue

Pneumonia - Classification d'images médicales par deep learning

PyTorch · scikit-learn · Grad-CAM · Projet académique en équipe - contribution personnelle détaillée ci-dessous

- Classification de radiographies thoraciques en 3 classes (Normal / Pneumonie bactérienne / Pneumonie virale), évaluée sur un jeu de test de 624 images
- Fine-tuning d'EfficientNet-B0 en transfer learning (PyTorch / torchvision) - **89 % d'accuracy et F1 macro 0.88**, meilleur résultat obtenu sur le projet
- Traitement du déséquilibre de classes par pondération, scheduler de learning rate, early stopping et augmentation appliquée au seul jeu d'entraînement : **la classe la plus difficile (VIRAL) atteint un F1 de 0.80**, contre 0.00 avec un CNN entraîné de zéro
- Baselines comparatives sur features réduites par PCA (40 composantes, 90 % de variance) : régression logistique à 76 % d'accuracy, forêt aléatoire à 66 %
- Explicabilité des prédictions par cartes d'activation Grad-CAM (hooks PyTorch), pour vérifier que les décisions reposent sur les zones pulmonaires et non sur des artefacts d'acquisition

Travel Order Resolver - Compréhension du langage naturel

Python · NLP · Extraction d'entités · Données SNCF

- Interprétation de demandes de trajet en français libre : extraction du départ et de la destination, détection des requêtes invalides, gestion des formulations ambiguës
- Évaluation par métriques et préparation d'un module de recherche d'itinéraire sur données SNCF

VerifDoc - API d'analyse documentaire par LLM

Python · FastAPI · LLM · JSON structuré · Projet personnel exploratoire

- API d'analyse d'attestations : identification du type de document, extraction des informations clés et détection d'anomalies
- Intégration LLM par prompting contraint et schéma de sortie JSON structuré, conçu pour être consommé par un système tiers

EXPÉRIENCE PROFESSIONNELLE

Alternant - Assistant Systèmes d'Information et Développement

SUPINFO Paris · Janvier 2024 – Septembre 2026

- Consolidation d'une base étudiants sur 6 promotions : conception d'un schéma normalisé et d'un script d'import Python vers SQL Server par opérations MERGE garantissant l'idempotence - **3 300+ profils et 45 000+ enregistrements de notes intégrés**
- Conception d'un outil de contrôle de format de données : **traitement ramené de 4-5 heures à 10 minutes** (-95 % de temps)
- Chaîne de génération documentaire par publipostage Word depuis Excel, pilotée par PowerShell : **d'une journée de travail à quelques minutes**
- Développement d'applications internes : TOROSS (React / Node.js / PostgreSQL, suivi du recrutement d'intervenants), CVthèque (React / Supabase, sécurisation par Row Level Security), ParcourSUP (.NET 9 WPF, deux bases SQL, génération documentaire, chiffrement des chaînes de connexion)
- Rédaction des spécifications fonctionnelles et techniques, et de la documentation utilisateur et développeur
- Automatisation des plannings pédagogiques via Excel/VBA sur 6 outils récurrents

Enseignement - Programmation C et C++

SUPINFO Paris · Année académique 2025-2026

- Animation de cours de développement C et C++ auprès d'étudiants de 2e et 3e année, et évaluation des travaux

Développeur Web - Stage

LiveMentor, Paris · Juin 2023

- Développement d'une fonctionnalité de filtrage et de tri, intégrée dans une base de code Ruby existante

Réceptionnaire après-vente - Alternance

Mercedes-Benz Véhicules Industriels, Saint-Denis · 2021 – 2022

- Relation client et coordination inter-services : traduction de contraintes techniques auprès d'interlocuteurs non spécialistes

FORMATION

Epitech - Architecte de Systèmes d'Information (Bac+5, titre RNCP niveau 7), spécialisation Intelligence Artificielle · 2023 – 2026

Epitech - Concepteur et Développeur Web / Mobile · 2023

Epitech - Développeur Intégrateur Web · 2023

Université Gustave Eiffel - Licence professionnelle Organisation et Management des Services de l'Après-Vente · 2022 (en alternance chez Mercedes-Benz Véhicules Industriels)

BTS Maintenance des Véhicules (2021) et Baccalauréat STI2D option Systèmes d'Information et Numérique (2019) - Lycée Condorcet, Montreuil

CENTRES D'INTÉRÊT

Veille technologique en IA générative et systèmes agentiques · Musculation · Automobile